



Prática de BI com Python Avançado

R esumo

Agora, vamos explorar o uso avançado de **Python** para **Business Intelligence (BI)**, com foco em **modelagem preditiva** e **análise de dados complexos**. Utilizando bibliotecas como **scikit-learn** para construção de modelos de **regressão linear**, os alunos serão introduzidos às técnicas necessárias para prever tendências de mercado e otimizar processos de tomada de decisão. A capacidade de criar **modelos preditivos eficazes** é uma habilidade essencial para qualquer profissional que busca **disruptar o mercado** com base em dados.

Segundo o **McKinsey Global Institute** (2023), “as empresas que utilizam modelos preditivos baseados em dados aumentam suas chances de superar a concorrência em até 30%”. Neste módulo, os nexialistas aprenderão como implementar esses modelos para prever **vendas**, **conversões** e outros **indicadores-chave de desempenho**, usando conjuntos de dados simulados que refletem situações reais de negócios.

1. Introdução à Modelagem Preditiva com Python

Neste módulo, o foco está na construção de modelos preditivos para dados de vendas e conversões. Utilizando **regressão linear**, os alunos serão guiados no processo de **dividir datasets**, treinar modelos e **avaliar a precisão** de suas previsões. O uso de bibliotecas como **pandas**, **scikit-learn** e **plotly** permite que a análise preditiva seja aplicada em diversos cenários

empresariais.

Exemplo de código usado para modelagem preditiva em um dataset de saúde:

Exemplo de código usado para modelagem preditiva em um dataset de saúde:

```
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

# Carregar o dataset
saude_df = pd.read_csv('/content/BI_saude_dados_simulados.csv')

# Selecionar as variáveis de interesse
X = saude_df[['Impressões', 'CTR', 'Lat', 'Long']]
y = saude_df['Conversoes']

# Dividir os dados em conjunto de treino e teste
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
random_state=42)

# Treinar o modelo de regressão linear
model = LinearRegression()
model.fit(X_train, y_train)

# Avaliar o modelo
y_pred = model.predict(X_test)
```

```
mse = mean_squared_error(y_test, y_pred)
print(f'Mean Squared Error: {mse}')
```

Esse exemplo de regressão linear oferece uma visão prática de como os dados de conversão no setor de saúde podem ser usados para prever resultados futuros com base em variáveis como **impressões, CTR e localização**.

2. Aplicação Avançada: Modelagem de Vendas

Uma aplicação mais avançada da modelagem preditiva envolve o uso de dados simulados de vendas, onde o objetivo é prever o impacto de **investimentos em publicidade, número de visitas ao site e preço médio do produto** nas vendas. Esse tipo de modelagem permite que os alunos explorem como **diferentes variáveis influenciam diretamente as vendas**, ajudando a identificar **fatores-chave para otimizar campanhas de marketing**.

Exemplo de código avançado para previsão de vendas:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
import plotly.express as px

# Carregar os dados simulados de vendas
sales_df = pd.read_csv('/content/BI_vendas_dados_simulados.csv')
```

```
# Selecionar variáveis de interesse
```

```
X = sales_df[['Investimento_Publicidade', 'Visitas_Site', 'Taxa_Conversao',  
'Preco_Medio_Produto']]  
y = sales_df['Vendas']
```

```
# Dividir os dados em treino e teste
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,  
random_state=42)
```

```
# Treinar o modelo de regressão linear
```

```
model = LinearRegression()  
model.fit(X_train, y_train)
```

```
# Avaliar o modelo
```

```
y_pred = model.predict(X_test)  
mse = mean_squared_error(y_test, y_pred)  
r2 = r2_score(y_test, y_pred)
```

```
print(f'Mean Squared Error: {mse}')
```

```
print(f'R^2 Score: {r2}')
```

Aqui, os alunos podem observar o **erro médio quadrado (MSE)** e o **coeficiente de determinação (R^2)**, que fornecem uma medida da qualidade do modelo. A ideia é que os nexialistas possam ajustar seus modelos e, potencialmente, usar técnicas mais avançadas, como regressão polinomial ou redes neurais, para melhorar a precisão das previsões.

3. Visualizações Interativas com Plotly

Um dos principais componentes da **análise avançada de BI** é a visualização de resultados. Usando **Plotly**, os alunos podem criar **gráficos interativos** que permitem a visualização de **previsões** versus **resultados reais**, ajudando a **identificar discrepâncias** e ajustar modelos de forma mais precisa.

Exemplo de criação de gráfico interativo:

```
import plotly.express as px

# Criando gráfico de dispersão interativo das previsões
pred_df = pd.DataFrame({'Real': y_test, 'Predito': y_pred})
fig = px.scatter(pred_df, x='Real', y='Predito', trendline="ols", title="Previsão de
Vendas - Simulação")
fig.show()
```

Essa visualização interativa oferece uma maneira clara e visualmente atraente de interpretar o desempenho do modelo preditivo. **Nexialistas** podem usar esse tipo de gráfico para **apresentar resultados** a stakeholders de forma mais convincente e detalhada.

Você pode acessar todo o código em nosso [Google Colab \(link\)](#) ou [neste documento online \(link\)](#).

Conclusão

O **Módulo 9** oferece uma introdução prática ao uso de técnicas de **modelagem preditiva** com Python. A capacidade de prever vendas, conversões e outras métricas críticas a partir de dados é uma habilidade fundamental para qualquer profissional que busca disrupção em sua área de atuação. Para os **nexialistas**, a aplicação de regressão linear e a

visualização interativa de resultados são ferramentas essenciais para **transformar dados em ações estratégicas**.

Dicas Práticas

- **Use a modelagem preditiva para planejar campanhas futuras:** Ao prever os resultados de campanhas, você pode alocar melhor os recursos de marketing.
- **Visualize sempre seus dados:** Gráficos interativos ajudam a identificar discrepâncias e ajustar modelos de forma eficiente.
- **Aprimore seu modelo:** Se os resultados não forem satisfatórios, considere explorar modelos mais complexos, como regressões não lineares ou aprendizado de máquina.

Conteúdo Bônus

Título: **“Modelagem Preditiva (Machine Learning) com Linguagem Python - Parte 1/2”**

Para quem deseja aprimorar suas habilidades em **Machine Learning** e análise de dados com Python, o canal **Data Science Academy** apresenta um vídeo ideal para mergulhar na modelagem preditiva. Neste conteúdo, você aprenderá a utilizar Python, uma das linguagens mais populares no mundo da ciência de dados, enquanto desenvolve seus conhecimentos em análise preditiva com o suporte de um assistente baseado em IA, como o ChatGPT. O vídeo é recomendado para aqueles que estão começando ou querem reforçar os fundamentos de programação e análise de dados,

proporcionando uma introdução prática e estruturada às principais técnicas de modelagem preditiva.

Referências

- **McKINSEY GLOBAL INSTITUTE.** Prediction: The future of CX. Disponível em: <https://www.mckinsey.com/capabilities/growth-marketing-and-sales/our-insights/prediction-the-future-of-cx>. Acesso em: 10 set. 2024.
- **KAGGLE.** Python for Predictive Analytics: A Guide. Disponível em: <https://www.kaggle.com/learn/predictive-analytics>. Acesso em: 10 set. 2024.
- **PYTHON Software Foundation.** Documentation for scikit-learn and plotly. Disponível em: <https://scikit-learn.org> e <https://plotly.com/python/>. Acesso em: 10 set. 2024.

Atividade Prática 9 - Prática de BI com Python Avançado

Título da Prática: Desenvolvimento de Dashboards Avançados com Previsão de Tendências e Análise de Comportamento do Usuário

Objetivos:

- Criar dashboards avançados que integrem previsões de tendências e análise de comportamento do usuário.
- Aplicar técnicas de machine learning para análise preditiva de dados de marketing e comportamento de usuários.

- Interpretar insights e utilizar previsões para otimizar as estratégias de marketing da aplicação.

Materiais, Métodos e Ferramentas:

- Python com bibliotecas *pandas*, *matplotlib*, *plotly*, e *scikit-learn*.
- Dados de marketing e comportamento do usuário em formato CSV, incluindo colunas como “Tempo de Sessão”, “Taxa de Conversão”, “Origem do Tráfego” e “Região”.
- Ambiente Jupyter Notebook ou Google Colab para manipulação de dados e visualização dos resultados.

Atividade Prática

Roteiro

1º. Passo) Preparação dos Dados:

- Importe os dados para o ambiente Python usando *pandas*.
- Realize uma limpeza inicial dos dados, verificando e tratando valores ausentes e ajustando o formato das colunas conforme necessário para a análise.

2º. Passo) Análise Preditiva:

- Utilizando *scikit-learn*, selecione um modelo simples de regressão linear ou árvore de decisão para prever a taxa de conversão com base nas variáveis disponíveis, como a origem de tráfego e o tempo de sessão.

- Divida os dados entre treinamento e teste, treine o modelo e gere previsões para as taxas de conversão futuras.

3º. Passo) **Construção do Dashboard:**

- Visualize as previsões geradas em um gráfico de linhas que mostre tanto os dados reais quanto os valores previstos.
- Inclua gráficos adicionais para análise do comportamento do usuário, como o tempo de sessão médio por origem de tráfego e a taxa de conversão por região.

4º. Passo) **Interpretação e Relatório:**

- Analise o desempenho do modelo preditivo e responda:
 - Qual a precisão da previsão de taxa de conversão para os próximos períodos?
 - Quais insights sobre o comportamento do usuário foram obtidos a partir dos dados analisados?
- Escreva um breve relatório (8 a 10 linhas) com recomendações para ajustes nas estratégias de marketing com base nos dados previstos e comportamentais.

Gabarito Atividade Prática

Exemplo de Respostas:

1. Previsão da Taxa de Conversão: O modelo de regressão linear apresentou uma precisão de 85% para a previsão das taxas de conversão, indicando que ele pode ser útil para projeções de curto prazo.

2. Insights de Comportamento do Usuário: Observou-se que o tempo médio de sessão está diretamente relacionado com a taxa de conversão; usuários que permanecem mais de 2 minutos têm uma taxa de conversão 30% maior.

3. Recomendações:

- Aumentar o foco nas campanhas que incentivam o engajamento prolongado do usuário, pois isso impacta diretamente a conversão.
- Aumentar o foco nas campanhas que incentivam o engajamento prolongado do usuário, pois isso impacta diretamente a conversão.

Ir para exercício