



Prática de Desenvolvimento de Solução de Machine Learning

Resumo

No Módulo 16, nos aprofundamos no desenvolvimento de sistemas de recomendação utilizando técnicas de Machine Learning (ML). A partir de um projeto prático, exploramos como o aprendizado de máquina pode ser aplicado para criar soluções de recomendação personalizadas, ressaltando a importância desse tipo de aplicação em cenários como e-commerce, plataformas de streaming, e até mesmo sistemas educacionais e de treinamento corporativo.

1. A Importância de Sistemas de Recomendação

Sistemas de recomendação são fundamentais em um mundo cada vez mais inundado por informações e opções. Eles ajudam os usuários a encontrar produtos, serviços ou conteúdos relevantes com base em suas preferências e comportamentos passados. Por exemplo, plataformas como Netflix e Amazon utilizam algoritmos de recomendação para fornecer sugestões que impulsionam engajamento e vendas, representando até 35% das receitas da Amazon (Forbes, 2023).

Principais Aplicações:

- E-commerce (sugestões de produtos)

- Streaming (filmes, séries, músicas)
- Educação (cursos e materiais de estudo personalizados)
- Redes Sociais (conteúdos e conexões)

2. Como Funciona o Machine Learning em Recomendação

O Machine Learning em sistemas de recomendação baseia-se em modelos que aprendem a partir dos dados de usuários e itens para prever preferências futuras. As técnicas utilizadas variam, mas incluem:

- **Filtragem Colaborativa:** Baseia-se no histórico de interações dos usuários, identificando padrões de comportamento semelhantes.
- **Filtragem Baseada em Conteúdo:** Utiliza atributos do item para recomendar produtos similares aos que o usuário já demonstrou interesse.
- **Modelos Híbridos:** Combinam as duas abordagens anteriores para criar recomendações mais precisas.

No código explorado, aplicamos a Filtragem Baseada em Conteúdo, que considera características de filmes e interações do usuário para criar recomendações personalizadas. A técnica de cosine similarity é usada para calcular a semelhança entre as características dos filmes curtidos pelo usuário e os filmes disponíveis, gerando recomendações mais precisas.

3. Construção e Avaliação de um Sistema de Recomendação

3.1 Desenvolvimento Prático com o Código Disponível O código fornecido utiliza a biblioteca scikit-learn para aplicar o algoritmo de similaridade de

cos seno e gerar recomendações de filmes com base em dados fictícios. A criação de um sistema de recomendação envolve os seguintes passos:

- **Coleta e Preparo dos Dados:** Como o código cria dados fictícios, é possível entender como preparar e tratar dados reais, que poderiam ser coletados de plataformas como Kaggle.
- **Treinamento do Modelo:** O modelo é treinado com base nas interações do usuário, como curtidas e avaliações de filmes.
- **Avaliação e Melhoria:** O modelo é avaliado por métricas como precisão e cobertura, ajudando a refinar o processo de recomendação.

4. Importância de Qualidade e Representatividade dos Dados

A qualidade e a representatividade dos dados são cruciais para o sucesso de sistemas de recomendação. Se os dados estiverem enviesados ou forem incompletos, as recomendações serão imprecisas ou limitadas. Por isso, é importante contar com uma variedade de fontes de dados e realizar limpeza e pré-processamento rigorosos.

5. Relevância dos Sistemas de Recomendação para Nexialistas

Para nexialistas, compreender a aplicação de Machine Learning em sistemas de recomendação é uma competência essencial. Esses sistemas criam valor ao oferecer experiências personalizadas e eficientes, destacando-se como um diferencial competitivo em muitos setores.

6. IA Generativa e a Construção de Soluções de Recomendação

Com a evolução de modelos como o ChatGPT e outras soluções de IA

generativa, a construção de sistemas de recomendação tornou-se mais acessível. Ferramentas como o ChatGPT podem ajudar na elaboração de códigos e no entendimento de conceitos complexos, facilitando a implementação, mesmo para quem não possui experiência em programação. Isso demonstra o potencial da IA generativa como um recurso valioso para criar soluções inovadoras e disruptivas em Machine Learning.

Dicas Práticas

1. Utilize plataformas como o [Google Colab \(link\)](#) para experimentar e testar o código disponível.
2. Acesse o código feito em aula pelo [colab \(link\)](#).
3. Busque dados reais em fontes como o Kaggle para aprimorar suas habilidades e aplicar o aprendizado em casos de uso mais avançados.
4. Experimente diferentes abordagens de recomendação e compare os resultados, entendendo as vantagens e limitações de cada método.
5. Explore o uso do ChatGPT ou outras IA generativas para solucionar dúvidas e criar variações do código.

Conteúdo Bônus

Título: **Como Criar um Modelo de Machine Learning de Recomendação**

Para quem quer aprender a desenvolver um **sistema de recomendação** com Machine Learning, o canal **Nerd dos Dados** apresenta um tutorial passo a passo para criar um modelo de recomendação de filmes. No vídeo, você

aprenderá como aplicar esse modelo não só para filmes, mas também para músicas, livros e outros produtos.

Usando **Python** e ferramentas como Numpy, Pandas e o algoritmo KNN, o conteúdo é ideal para quem deseja entender as etapas práticas de um projeto de recomendação, similar ao que vemos em plataformas como Netflix e Spotify. É uma excelente oportunidade para aplicar Machine Learning e personalizar recomendações em diferentes contextos.

Referências Bibliográficas

Forbes. How Machine Learning Will Transform Your Industry. Disponível em: <https://www.forbes.com/councils/forbestechcouncil/2023/02/27/how-machine-learning-will-transform-your-industry/>. Forbes. Acesso em: 24 set. 2024.

Kaggle. The Data Science Community for Data Sets and Projects. Disponível em: <https://Kaggle.com> . Acesso em: 24 set. 2024.

OpenAI. ChatGPT e a Revolução da IA Generativa. Disponível em: <https://OpenAI.com>. Acesso em: 24 set. 2024.

Sklearn. User Guide for Cosine Similarity. Disponível em: <https://scikit-learn.org>. Acesso em: 24 set. 2024.

Atividade Prática 16 - Prática de Desenvolvimento de Solução de Machine Learning

Título da Prática: Personalização da Experiência do Usuário com Machine Learning

Objetivos:

- Implementar uma solução de machine learning para personalizar a experiência do usuário na aplicação.
- Utilizar algoritmos de recomendação para sugerir conteúdos relevantes com base no comportamento do usuário.
- Integrar a funcionalidade de recomendação ao backend da aplicação, permitindo uma experiência interativa.

Materiais, Métodos e Ferramentas:

- Python com bibliotecas de machine learning como *scikit-learn* ou *TensorFlow*.
- Dados de interação do usuário, como histórico de navegação, preferências e ações realizadas na aplicação.
- Acesso ao backend da aplicação (dockerizado) para integração da funcionalidade de recomendação.

Atividade Prática

Roteiro

1º. Passo) Preparação dos Dados para Treinamento:

- Reúna os dados de interação dos usuários, como histórico de visualizações, cliques, e tempo de permanência nas páginas.
- Organize esses dados em um formato adequado para treinamento, como uma matriz de preferências do usuário.

2º. Passo) Treinamento do Modelo de Recomendação:

- Selecione um algoritmo de recomendação (ex.: filtragem colaborativa ou filtragem baseada em conteúdo).
- Treine o modelo com os dados disponíveis e valide a acurácia das recomendações geradas.

3º. Passo) **Integração do Modelo com o Backend:**

- Implemente o modelo de recomendação no backend da aplicação, preferencialmente dentro do ambiente dockerizado.
- Configure o sistema para que o frontend da aplicação possa acessar e exibir as recomendações geradas pelo modelo em tempo real.

4º. Passo) **Testes e Avaliação:**

- Realize testes com diferentes perfis de usuários para avaliar a precisão e a relevância das recomendações.
- Ajuste o modelo com base nos resultados e melhore os parâmetros de personalização.

Gabarito Atividade Prática

Exemplo de Respostas:

1. **Preparação e Treinamento:** Os dados foram organizados em uma matriz de preferências e o modelo de filtragem colaborativa foi treinado, atingindo uma acurácia de 87% nas recomendações.

2. **Integração com Backend:** O modelo foi implementado com sucesso no backend da aplicação dockerizada, permitindo que as recomendações sejam acessadas em tempo real no frontend.

3. **Recomendações:**

- Refinar o modelo para considerar sazonalidade ou tendências de comportamento dos usuários.
- Implementar um feedback loop que permita ao usuário avaliar as recomendações, ajudando a melhorar continuamente o modelo.

Ir para exercício